

Projet de Classification Supervisée


Prédiction de Sinistres Assurance Automobile

Objectif : Déterminer la probabilité qu'un client dépose une demande d'indemnisation (`outcome`).

Dataset : 10 000 entrées, 18 variables.

1. Analyse et Nettoyage des Données

- **Outliers** : Suppression des `speeding_violations > 100`.
- **Variables** : Suppression de `id` et `postal_code`.




2. Préparation des Données

- **Imputation** : Médiane (numérique) et Mode (qualitatif).
- **Encodage** : Mapping manuel pour préserver la hiérarchie (`Income` , `Education`).
- **Normalisation** : `StandardScaler` pour équilibrer les échelles.

Justification : Garantir que les variables à forte magnitude (km) ne dominent pas les variables à faible magnitude (scores).

3. Corrélations & Relations

- **Top impacts** : Expérience (-0.50), Âge (-0.45), Revenu (-0.42).



4. Théorie : Régression Logistique

- **Modèle** : $\log\left(\frac{p}{1-p}\right) = \beta_0 + \sum \beta_i x_i$
- **Apprentissage** : Minimisation de la **Log-Loss**.
- **Calculs** : Détermination des poids β_i et de l'ordonnée à l'origine β_0 .

Note : Modèle choisi pour son équilibre entre performance et interprétabilité métier.


5. Évaluation & Validation

- **Accuracy Test : 83.94% | F1-Score : 74.22%**
- **Validation Croisée : 84.12% ± 0.78%** (Haute stabilité).

Type	Nombre	Description
Vrais Négatifs	1216	Sans sinistre, bien prédit
Vrais Positifs	462	Sinistre réel, bien prédit

Le modèle est robuste face aux variations du jeu de données.

6. Comparaison Multi-Modèles



Analyse : La Régression Logistique (Logit) domine. Le KNN progresse avec la distance Manhattan mais reste en deçà sur le F1-Score.

7. Conclusion & Mise en Production

Choix Final : Logit Optimisé

- **Meilleure performance globale** (84% accuracy).
- **Paramètres** : `C: 0.1, solver: 'liblinear'`.

Production

- Modèle sérialisé via **Pickle** (`best_model.pkl`).
- Prêt pour une intégration logicielle immédiate.

Merci !

Questions ?