

Projet de classification supervisée

Prédiction des sinistres en assurance auto

Objectif : estimer la probabilité qu'un client déclare un sinistre afin d'aider la décision métier.

Dataset : 10 000 clients, 18 variables (profil socio-éco, historique de conduite, véhicule).

Contexte et cible

Problématique : identifier les profils à risque de manière fiable et interprétable.

Variable cible : `outcome` (1 = sinistre, 0 = aucun).

Contraintes : données hétérogènes, valeurs manquantes, variables ordinales et catégorielles.

Approche : pipeline complet (nettoyage → encodage → normalisation → modèles → évaluation).

Pipeline de préparation

- **Nettoyage** : suppression des valeurs aberrantes et colonnes non informatives.
- **Imputation** : médiane pour les numériques, mode pour les qualitatives si besoin.
- **Encodage** : mapping manuel pour les ordinales, encodage binaire pour les autres.
- **Normalisation** : StandardScaler pour rendre les variables comparables.
- **Sortie** : données numériques prêtes pour l'apprentissage.

Nettoyage des données

- **Outliers** : suppression des lignes où `speeding_violations > 100` (erreurs de saisie extrêmes).
- **Colonnes retirées** : `id` (identifiant aléatoire) et `postal_code` (faible granularité).
- **Pourquoi** : éviter les biais sur les distances et les coefficients des modèles.

Résultat : distribution stabilisée, bruit réduit, variables plus cohérentes.

Valeurs manquantes et encodage

- **Valeurs manquantes** : `credit_score` et `annual_mileage` imputés par la médiane.
- **Raison** : la médiane est robuste aux extrêmes et limite l'introduction de bruit.
- **Encodage ordinal** : `education`, `income`, `driving_experience` mappés pour préserver la hiérarchie.
- **Encodage binaire** : `vehicle_year`, `vehicle_type` via LabelEncoder.

Impact : le modèle conserve le sens de progression des variables ordinales.


Normalisation (StandardScaler)

- Les variables ont des échelles très différentes (ex: `credit_score` vs `annual_mileage`).
- Sans normalisation, les variables à grande amplitude dominant l'apprentissage.
- Le centrage-réduction garantit une influence comparable sur la régression logistique et le KNN.

Résultat : distances et coefficients plus équilibrés.


Graphiques : distributions

Les histogrammes montrent des formes variées (asymétrie, dispersion), ce qui justifie la normalisation.



Graphiques : relations entre variables

La scatter matrix met en évidence des séparations partielles, sans frontière nette. Cela favorise un modèle probabiliste plutôt qu'une règle déterministe.



Corrélations clés avec **outcome**

- **driving_experience (-0.50)** : facteur protecteur majeur.
- **age (-0.45)** : moins de sinistres chez les conducteurs plus âgés.
- **income (-0.42)** : revenus plus élevés → moins de sinistres.
- **vehicle_ownership (-0.38), past_accidents (-0.31), credit_score (-0.31)**.
- **vehicle_year (~0.29)** : effet positif sur le risque.

Lecture : corrélation $\neq$ causalité, mais utile pour prioriser les variables.

Modèles et validation


Modèles comparés (GridSearchCV) :

- Régression logistique (baseline interprétable)
- KNN (distance entre profils)
- Perceptron (frontière linéaire simple)

Validation :

- Split train/test 80/20
- Cross-validation 5 folds
- Score moyen : **84.12% $\pm$ 0.78%** (stabilité du modèle)

Comparaison visuelle des modèles



Comprendre les métriques

- **Accuracy** : part de prédictions correctes, mais sensible au déséquilibre des classes.
- **Précision** : proportion de sinistres réels parmi les clients prédits à risque.
- **Rappel** : proportion de sinistres détectés parmi les sinistres réels.
- **F1-score** : compromis global entre précision et rappel.

Pourquoi : une seule métrique ne suffit pas pour mesurer le risque métier.

Résultats du modèle final

Régression logistique optimisée (`C=0.1` , `solver=liblinear`).

Métrique	Valeur
Accuracy	83.94%
Précision	74.88%
Rappel	73.57%
F1-score	74.22%

Lecture : bon compromis entre détection et limitation des fausses alertes.

Matrice de confusion (lecture métier)

- **Vrais négatifs** : 1216
- **Vrais positifs** : 462
- **Faux positifs** : 155
- **Faux négatifs** : 166

Interprétation : les faux négatifs sont les sinistres manqués ; le seuil peut être ajusté si l'objectif devient prioritairement le rappel.

Conclusion

La **régression logistique** est retenue pour sa performance et son interprétabilité.

Elle fournit un modèle robuste, explicable aux équipes métier, avec un bon équilibre entre précision et rappel.